



长安十二时辰

背后的技术秘籍

从智能算法到音视频创新技术

阿里文娱 **技术** | 阿里云开发者社区



Alibaba Group
阿里巴巴集团

优酷技术品牌出品



「阿里文娱技术」公众号



「阿里云开发者社区」



「阿里技术」微信公众号

扫一扫二维码图案，关注我吧

I 目录

《长安十二时辰》背后的文娱大脑：如何提升爆款的确定性？	1
解密《长安十二时辰》背后的酷看体验	13
《长安十二时辰》4k 和 HDR 的超高清体验	23
优酷智能档的三个技术挑战和解法	28
爆红《长安》也是盗链者眼中的“肥肉”，阿里专家解析防盗链系统	35
详解优酷媒资中台架构：日均百亿调用下的高可用平台	39

《长安十二时辰》背后的文娱大脑： 如何提升爆款的确性？

作者 | 阿里大文娱资深算法专家 牧己

据优酷北斗星数据显示，《长安》的“北斗星日指数”高达100W+，普通热门剧的“北斗星日指数”为50-60W，是普通热剧的2倍。

爆款稀有，所以可贵。长视频爆款的复杂和挑战主要来源于不确定性，并且这种不确定性渗透在内容的采集、宣发和投放的所有环节中。以《长安》为例，拍摄217天，从定剧本、选角色、搭场景、道服化、到拍摄、后期处理，以及宣发和投放等等，每一个环节都可能影响最后效果的呈现。

长视频爆款的复杂与挑战：较高的不确定性



长视频内容的三大不确定性：

第一个不确定叫做延迟满足和信息不完备。长视频通过组织多个有效的事件序列，形成价值转换，刻画出不同人物，最终体现一个或多个价值观，整个过程需要很

多剧集逐渐被用户感知。每个用户对于内容的偏好点和关注点不同，获取的只是内容片面的信息，信息的不完备性，导致对于内容理解的偏差。

优酷主要通过 NLP/CV/ 语音的语义理解 &KG 等技术，进行“内容外延的解构”和“内容内核的创作理解”，获取到内容从外到内的各维度数据，保证相对的确定性。

第二个不确定是涉及工种极多的复杂系统工程。需要对复杂过程中的关键点数字化、模式化，对过程进行量化衡量 & 计算。

第三个不确定来自于内容本身的专业技能。如何与流量商业价值相结合，内容人在内容创作过程中会加入各种专业的技术，如在大场景的还原上，镜头语言的处理上，服化道的配置上，画面的构图上等等。但是这些技术，哪些是用户关注的？哪些是用户不在乎的？这很重要，涉及到最终的流量商业价值。所以，优酷要在技术上解决用户理解和用户心理学的问题，洞察用户偏好，将用户和内容做关联。

内容产业发展背后的趋势思考

商业需要确定性，而内容具有极强的不确定性，如何依靠技术达到平衡？这是内容产业发展所引发的思考。

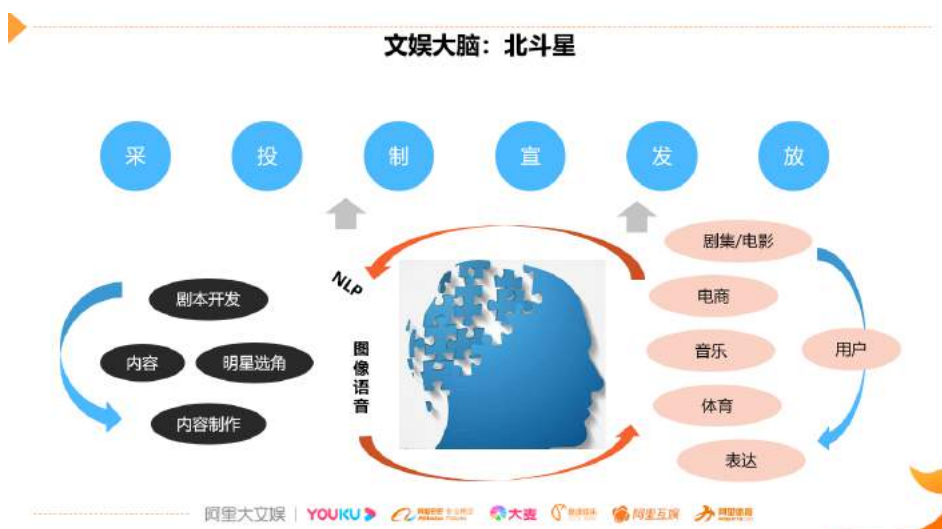
爆款的演变



在崇尚个性化的当下，爆款也从“全民爆款”演进成“圈层爆款”，非圈层受众对某些内容完全没有感知，与之前万人空巷的气势完全不同。

爆款《长安》可复制吗？向算法和数据榨取确定性

从内容的不确定性出发，优酷搭建了人机结合的智能系统即“北斗星”，它是一个具有思考能力的 AI 大脑。在采、投、制、宣、发、放的内容全生命周期中，都融入了 AI 能力，目的就是向算法和数据榨取确定性。

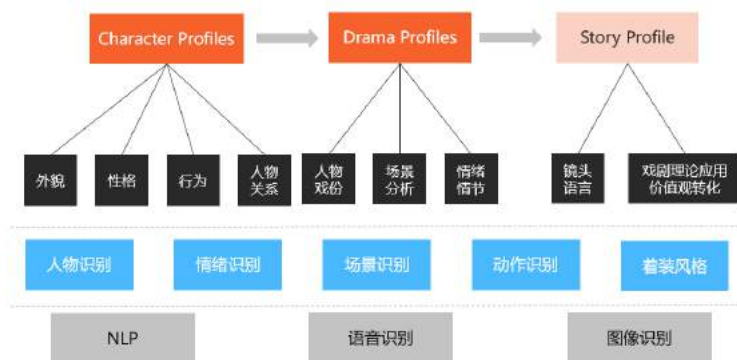


1. 基础能力：内容创作理解能力

处理庞大信息对于人工智能来说是“小菜一碟”，难的是提升内容创作中的理解、预测和挖掘能力。内容创作理解能力，是对剧本进行智能化的分析和挖掘。

内容主创班子是一个极强的系统工程，在上图左侧会基于内容理解做分析和挖掘，而右侧会基于数据对左侧内容理解做“量化”，从而在内容创造阶段提供类似大脑的思考和决策能力，提高这部分的确定性。

基础能力：内容创作理解能力



内容创作有自身规律，内容创作理解就是围绕基于镜头语言和“两千多年的戏剧理论应用价值观”转化为技术能力，即对剧本和视频的智能理解。

《长安》主创戏份评估



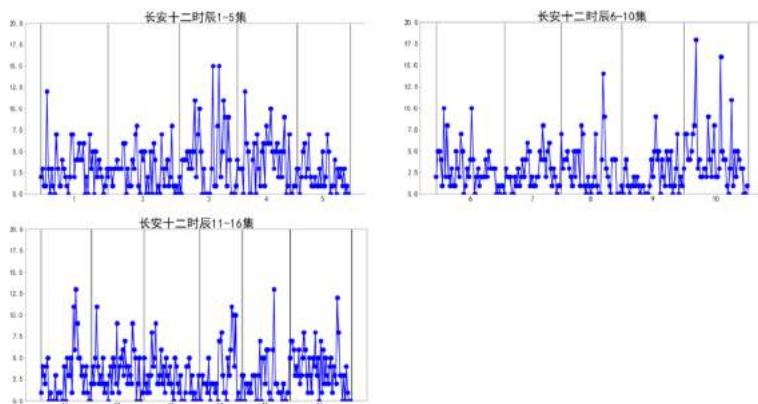
以《长安》剧本分析为例，全剧本共有 120 多个人物，主创戏份评估如下：

- 1) 张小敬的戏份占 15%，李必占 10%，檀棋、龙波、姚汝能分别占 5%、4%、3%；
- 2) 张小敬和李必在全剧分别贡献了 90% 以上的人物关系；
- 3) 檀棋贡献了 80% 以上的人物关系，在剧中作为功能性人物推动剧情发展。

对《长安十二时辰》剧本的角色交互分析如下：

- 1) 张小敬与檀棋的交互最多；
- 2) 李必与檀棋、徐宾交互较多；
- 3) 相比 IP 剧本减少了张小敬和李必的交互。

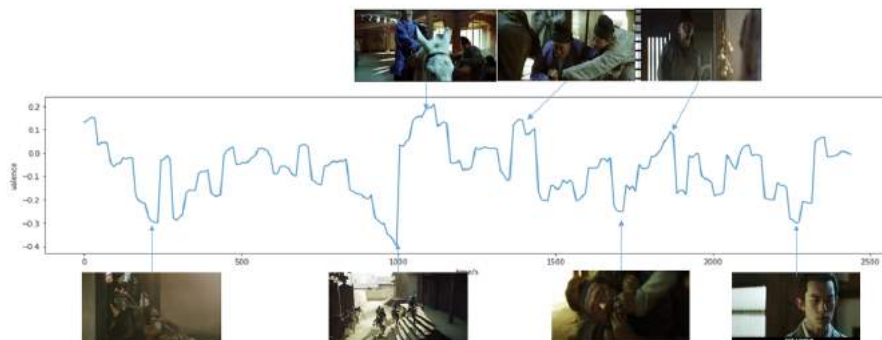
《长安》剧情分析



阿里大文娱 | YOUKU 优酷 爱奇艺 腾讯视频 优酷 阿里大文娱 优酷 阿里大文娱 优酷

对《长安》中人物情绪进行分析发现：在前 16 集中，第 3 集和第 10 集出现了情绪表达的高峰，为剧情创造紧张情节。

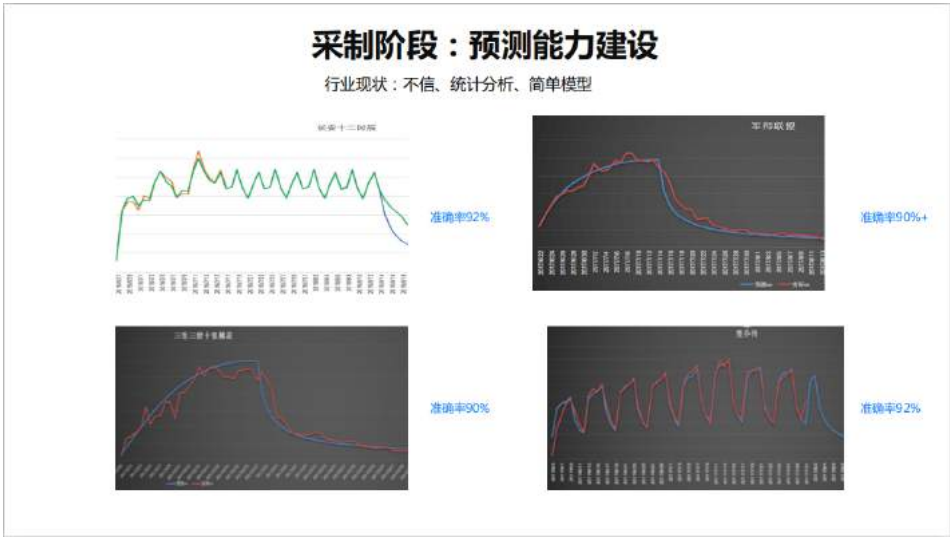
《长安》剧情：情绪评估



阿里大文娱 | YOUKU 优酷 爱奇艺 腾讯视频 优酷 阿里大文娱 优酷 阿里大文娱 优酷

对于《长安》第一集的成片进行多模态，包括声音与图像。图像综合了演员表情、场景、动作等分析，预测出一条“用户观影情绪曲线”，后续结合用户真实观看情况对数据进行升级优化。

2. 采制阶段：预测能力建设



对于不确定的事情，如果可以计算出不确定性有多强，便可有效提升商业决策效率，提高决策结果的确定性。基于此，建设识别和理解不确定性的预测模型。

预测困难挑战

- **数据的问题：**
 - 数据量不够，带Label不够
 - 数据不干净
 - 信息非完备问题
- **模型的问题：**
 - 常规的预测思路：数据+简单模型、数据+逼近能力强黑盒模型
 - 常规思路本质：黑盒模型逼近真相
 - 存在问题：
 - 复杂机制很难通过样本进行覆盖
 - 很难深入理解问题本质
 - 很难跨领域进行举一反三学习
- **应用的问题**
 - 在不确定世界里寻求确定性

预测中会面临数据、模型和应用三方面问题。数据问题分为数据量不够，数据不干净和信息不完备。模型的问题包括复杂机制很难通过样本进行覆盖、很难深入理解问题本质和很难跨领域进行举一反三学习。从优酷的经验出发，是正确识别应用上的不确定性可以在应用上有很好的改观。



常规解法也分为数据、模型和应用三方面解法。数据量由数据采样和数据生成解决，数据不干净由数据清洗解决，数据不完备由 Domain Knowledge&KG 解决。应用解法中不确定分析模型有 Belief Network 等解法。



根据之前解决的问题，解法可以分为四层：



第一层是基础层。分为 KG&Domain Knowledge/Feature Engineering 和学习加速；

第二层是数据层。分为数据生成 (SMOTE)，隶属度变换 (高斯隶属度) 和半监督学习；

第三层是模型层。通过 DNN 和 Relation Net 以及 MTL 相结合，降低过拟合，提高模型的学习能力；

第四层是 Uncertainty Learning，基于变分推断的框架进行内容不确定性的预测。

SMOTE (Synthetic Minority Oversampling Technique) + 生成 隶属度变换 (高斯隶属度变换)




阿里大文娱 | YOUKU | 阿里巴巴集团 | 大麦 | 优酷 | 阿里互娱 | 阿里影业

SMOTE (Synthetic Minority Oversampling Technique)，合成少数类过采样技术。

它是基于随机过采样算法的一种改进方案。由于随机过采样，采取简单复制样本的策略来增加少数类样本，这样容易产生模型过拟合的问题，使得模型学习到的信息过于特别 (Specific) 而不够泛化 (General)。SMOTE 算法是对少数类样本进行分析，并人工合成新样本添加到数据集中，新样本的公式为 $x_{new} = x + rand(0,1) \times |x - x_n|$ ，生成的样本可直接应用到项目中，但提升效果不稳定。

Variational Inference

- Approximate $p(\omega|\mathbf{X}, \mathbf{Y})$ with simple dist. $q_\theta(\omega)$
- Minimise divergence from posterior w.r.t. θ



Yarin Gal, Uncertainty in DL 2015

- Let $q_\theta(\omega)$ to approximate posterior $p(\omega|\mathbf{X}, \mathbf{Y})$

- KL divergence to minimise:

$$\text{KL}(q_\theta(\omega) \parallel p(\omega|\mathbf{X}, \mathbf{Y})) \\ \propto -\int q_\theta(\omega) \log p(\mathbf{Y}|\mathbf{X}, \omega) d\omega + \text{KL}(q_\theta(\omega) \parallel p(\omega)) \\ =: \mathcal{L}(\theta)$$

- Approximate the integral with MC integration $\tilde{\omega} \sim q_\theta(\omega)$:

$$\hat{\mathcal{L}}(\theta) := -\log p(\mathbf{Y}|\mathbf{X}, \tilde{\omega}) + \text{KL}(q_\theta(\omega) \parallel p(\omega))$$

Minimise divergence between $q_\theta(\omega)$ and $p(\omega|\mathbf{X}, \mathbf{Y})$:

- Repeat:

- Sample $\mathbf{z}_J \sim \text{Bernoulli}(\rho)$ and set

$$\tilde{\mathbf{W}} = \mathbf{M}_J, \text{diag}(\{\tilde{\mathbf{z}}_J\}_{j=1}^K)$$

$$\tilde{\omega} = \{\tilde{\mathbf{W}}_j\}_{j=1}^L$$

- Minimise (one step)

$$\hat{\mathcal{L}}(\theta) = -\log p(\mathbf{Y}|\mathbf{X}, \tilde{\omega}) + \text{KL}(q_\theta(\omega) \parallel p(\omega))$$

w.r.t. $\theta = \{\mathbf{M}_j\}_{j=1}^L$ (set of matrices).

阿里大文娱 | YOUKU 优酷视频 阿里影业 大麦 阿里影业 阿里影业 阿里影业 阿里影业

Variational Inference (last page)

Instead, **predictive mean**, approx. with MC integration:

$$\mathbb{E}_{q_\theta(\mathbf{y}^*|\mathbf{x}^*)}(\mathbf{y}^*) = \frac{1}{T} \sum_{t=1}^T \tilde{\mathbf{y}}(\mathbf{x}^*, \tilde{\omega}_t)$$

with $\tilde{\omega}_t \sim q_\theta(\omega)$.

- In practice, **average stochastic forward passes through the network** (referred to as “MC dropout”).⁵

- Dropout after convolutions and averaging forward passes = **approximate inference in Bayesian convnets**.⁶

$$\text{Var}(\mathbf{y}^*) = \tau^{-1} \mathbf{I} + \frac{1}{T} \sum_{t=1}^T \tilde{\mathbf{y}}(\mathbf{x}^*, \tilde{\omega}_t)^T \tilde{\mathbf{y}}(\mathbf{x}^*, \tilde{\omega}_t) - \mathbb{E}(\mathbf{y}^*)^T \mathbb{E}(\mathbf{y}^*)$$

结论:

- 实验效果, VI更好
- Laplace逼近的方式假设条件更多, 而VI更加严谨
- 另外逻辑上讲, 逼近Laplace的函数是选择最优解, 而VI更像 Ensemble

阿里大文娱 | YOUKU 优酷视频 阿里影业 大麦 阿里影业 阿里影业 阿里影业 阿里影业

这一部分可以在网上参考“贝叶斯 Network”, 重点看它如何利用“变分”得到最后结果。

3. 宣发阶段：挖掘能力建设



挖掘能力更多应用于已经发生的事件，使其更具有确定性。上图是《长安》播出后，每一分钟用户的收视状况、复看状况和弹幕状况，再结合每一时间段的剧情内容对用户喜好做更精准的分析，以此来更好的宣推和挖掘。

内容产业是个不确定性非常高的产业，越是爆款就越有不确定性。互联网下半场我们积累了特别多的数据，AI能力也得到了前所未有的发展，我们建立了“文娱大脑”北斗星、AI剧本等内容形式的挖掘能力，和采买不确定性预测的评估能力，以及对于宣发挖掘的能力，都在业务应用上取得了不错的成绩。

传统的内容制作领域，依然依赖人的经验，在强人工智能尚遥远的情形下，如何结合机器AI和人工经验是个永恒的主题，例如结合符号主义（计算机学派）和连接主义（仿生学派）的智能。因此，我们将在两个方向发力：1）决策引擎的建设，包括结合人工逻辑规则和机器学习，不确定性分析框架和经久不衰的贝叶斯因果决策，以及神经元化的混合智能计算框架。2）量化的心理学研究也越来越重要，我们也会推进这部分探索。

解密《长安十二时辰》背后的酷看体验

作者 | 阿里大文娱无线开发专家 卜道


从“叉手礼”、“水盆羊汤”、“酒晕妆”这些唐朝人生活细节，到精美的坊间造型、充满意境的诗词歌赋，《长安十二时辰》不仅以缜密剧情赢得赞誉，更还原了一个真实的大唐长安。在精良制作之上，如何让观众感受 1000 多年前的长安风情、更深度的理解剧情呢？

想必细心的观众已经发现，优酷《长安》中出现了很多有人情味的“黑科技”，比如百科 tips、角色伴侣、剧情进展图等，让用户“边看剧边互动”，这就是优酷的酷看模式。酷看模式在移动端采用了多路流的同屏展示、智能平滑切换、精准同步和动态化渲染等技术。其中动态化渲染、子母屏和多路流同步播放是酷看模式在端侧的核心能力，能够做到多路流、多机位视频帧级同步播放。本文接下来要讲一讲和《长安》相关的背后的一些核心技术。

一、播放器业务框架

优酷的播放器业务框架以一个简单而优雅模型解构了所有的播放器业务，在该框架下播放业务是由一组彼此独立的插件组合实现的。它适应了复杂的播放业务场景，支持着众多围绕播放业务的团队并行开发。通过技术架构的解耦带来与之相关的技术团队的组织架构的解耦。

1. 播放器视图模型



如上图所示，该模型可以描述为：

- 1) 播放器由多个层组成；
- 2) 层容器中布局插件；
- 3) 播放器发布消息；
- 4) 插件订阅消息；
- 5) 层和插件信息来自配置文件。

2. 核心特性

该框架在设计之初就确定了一系列的优良特性作为设计目标，核心的特性列举如下：

1) 基于消息，事件驱动

引入事件 / 订阅的消息机制，插件按需订阅播放器的事件，根据优先级响应和消费消息；

2) 按需配置，自由组合

支持从 xml 配置文件加载层和插件的配置信息，各个业务方在接入业务框架时以搭积木的方式排列组合构造播放器；

3) 插件解耦，互不依赖

将所有的播放功能及业务模块解耦为彼此独立的插件，插件之间以消息机制进行通信；

4) 标准明确，支持扩展

框架会提供一批功能丰富的标准插件，插件可分组管理，业务方可根据自己的需求定制插件来替换默认实现，也可以新增插件；

5) 多例共存，彼此隔离

即可有多个播放器在一个页面内同时运行，并且从不同的配置创建。

3. 为业务开发带来的变化

1) 技术架构开放化

以插件的形式隔离和封装不同的业务，清除业务之间的显式依赖。基于新的业务框架，业务方一方面可以将标准插件排列组合创建个性化的播放器，尤其是一些基础插件避免重复劳动；另一方面可以自定义新插件替换默认实现或者添加新业务插件，技术框架层面上支持业务团队独立完成播放器一整套的个性化定制。

2) 业务开发标准化

在该播放器框架下，业务插件的顶层设计是统一的、标准化的。包括一致的构造函数、一致的创建过程、一致的生命周期、一致的播放器事件响应机制等。对于不同团队业务代码之间的相互理解和跨团队统一作战都有优势。在标准化的过程中，更容易产出一些通用插件被更多的业务所复用。

3) 播放能力服务化

通过引入中间层，播放服务与播放业务边界逐渐清晰，彻底结束业务代码与播放能力代码犬牙交错的局面，彼此松绑，并行前进，播放服务的内聚收敛也具备了向 OTT 等业务类库级输出的可能性。

二、酷看百科

酷看百科主要是在视频播放过程中给出一些类似百科的，辅助用户观看的介绍性

内容。技术上的需求主要来自两个方面：

一方面面向运营，运营希望有一个常态化的运营工具，简单的通过运营后台修改配置就完成投放，无需技术同学辅助，客户端也不需要频繁发版本；

另一方面面向用户体验，产品希望能够根据用户的偏好和视频的内容做到 UI 风格多样可动态调整的展示，能够较好的与内容融合。



剧中关于不良人的解释即为一处百科的投放

核心技术点

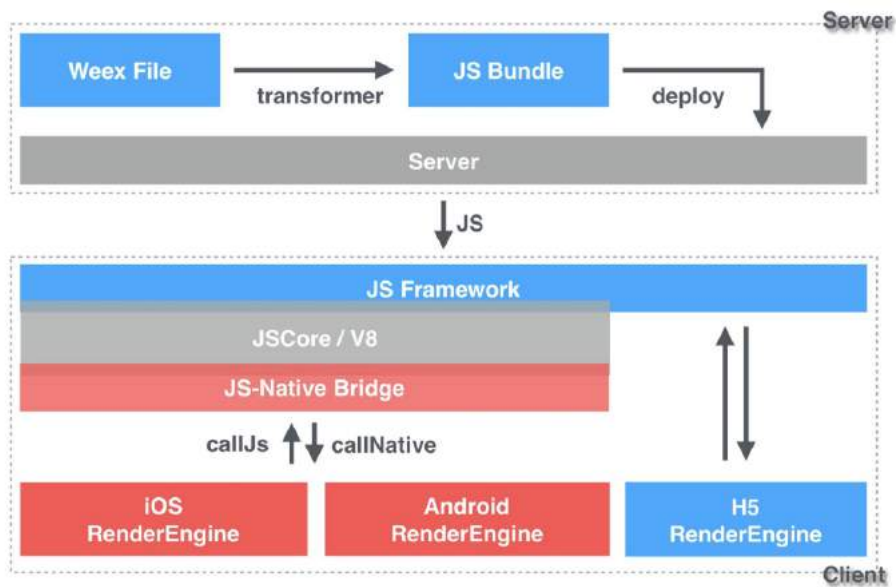
为了实现“动态化的内容投放和播放模式切换”，就必须解决两个具体问题。即：

- 1) 播放器如何进行不同播放模式的切换
- 2) 端侧采用什么技术来实现动态化渲染

对于问题 1，在播放器业务框架下我们将百科相关的业务也作为一组插件来实现，并且对播放器的业务插件进行分组，利用框架中插件管理器的插件热拔插能力动态的启用和禁用不同组的业务插件。

对于问题 2，我们采用了阿里开源的 Weex 来实现 UI 动态化渲染，无需发版即

可实现动态化布局，再结合后端的定投能力，就能够实现按照不同样式模版来动态的投放组件。



weex 架构示意图

三、子母屏

子母屏是酷看中使用较多的一种形态。

所谓子母屏就是将设备区域划分为两大部分，同时投放多屏内容。占据主视频焦点的区域称为母屏，一般用来播放正片；侧边较小的区域称为子屏，一般用来投放与正片内容相关的辅助或者互动性内容。类似于直播比赛时，在画面中引入场边教练采访或者赛况数据。

核心思想：分离母屏正片和子屏的可运营资源

传统做法是直接将“要在副屏展示的内容”通过后期制作，以合流方式直接压入正片视频流中，不过在《长安十二时辰》中我们没有采用这种方式。因为这种方式的缺点很明显：

- 1) 对用户不友好，缺乏互动性且难以按照用户的偏好差异投放；

- 2) 对制作不友好，互动资源和正片资源直接耦合；
- 3) 对运营不友好，严重依赖后期制作无法独立运营；
- 4) 对商业化不友好，广告内容和正片资源直接固化。

这些问题的症结在于合流的方式导致相关内容以一种较为粗放的、固化的方式投放给观众，无视观众的偏好；同样也忽略了多层次精细化的运营需求，这种基于媒体资源的强绑定关系使得正片内容和运营内容组合关系变得固化且单一。

基于此，我们将母屏和子屏的资源解耦。即不在制作时合流，而是让正片内容和运营内容严格分离，分开存储和投放。副屏的内容投放将完全交由运营同学，运营同学从模版库中选择相应的模版即可快速预览和投放，不再依赖后期制作。

核心技术点

我们这里只讲一个较为核心的点即播放器双屏容器，双屏的内容投放是彼此分离的，它是我们后续各种玩法的载体。

3.1 播放器双屏容器

首先要解决的是子母屏容器的搭建问题。对于双屏容器有一些具体的特性要求：

- 1) 母屏的缩放尺寸能够根据不同的屏幕宽度和视频资源宽度自适应；
- 2) 子屏同母屏一样具有交互性，能够响应用户的手势；
- 3) 母屏上下区域都是可投放可交互的运营位；
- 4) 弹幕、进度条等组件可以根据需求跟随或者脱离母屏。

设计师给出了母屏和子屏可以相互交错叠压的酷炫方案，甚至还有延伸至背景的异形遮罩效果，对于动效同步的要求也较高，母屏缩放和子屏移入的动效同步。为了解决缩放适配问题，我们写了一套自适应的容器布局算法，基本的思路是对母屏的布局按照统一规则进行划分，将子屏嵌入到母屏的某一层中，能够基于服务端下发的配置和视频的尺寸计算出最终子母屏容器的布局模型和动效参数，然后再根据这套模型驱动渲染视图以达到预期效果。

双屏想要具备交互性响应用户手势主要的阻碍在于 Z 轴上有覆盖在视频层上的诸如弹幕等其他的遮罩层会拦截掉系统的触屏事件，为此我们设计了手势插件作为触屏

事件的代理，由这个代理按照优先级转发手势事件相关的订阅者，这样就突破了视图层级对手势的限制。



《这就是街舞2》，边看街舞边给选手投毛巾。

四、双流同步播放

在解决了子母屏的自动布局和交互性问题之后，用子母屏来承载双流流的视频同步播放则是更具挑战的问题。

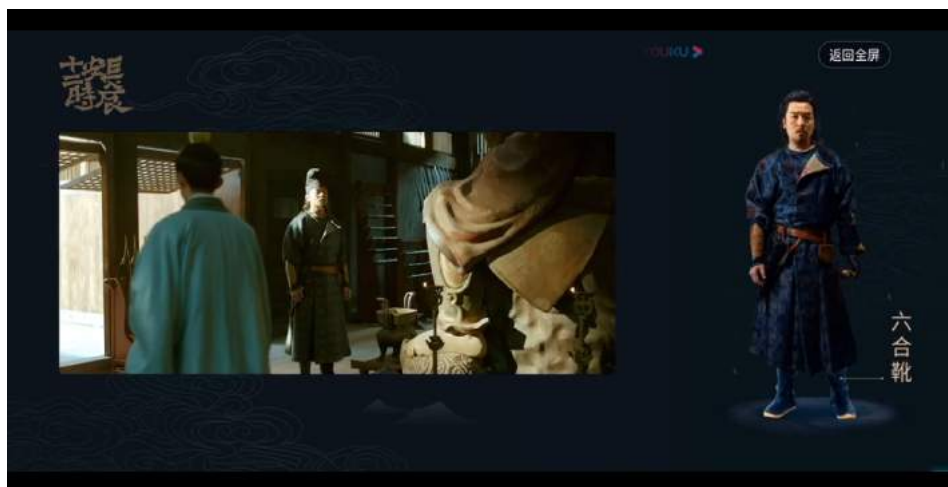
双流流播放有两个备选方案：

- 1) 单播放器实例，子屏和母屏共同作为一个或者一组播放器插件存在，共享上下文；
- 2) 双播放器实例，子屏和母屏各作为一个播放器实例存在，具有各自的上下文；

我们选择了双实例的方案，因为：

- 1) 产品形体来看，主副屏之间的主从关系是相对明确的，体现为副屏对主屏的单向状态订阅和同步；
- 2) 工程角度来看，保持模型的简单性是有益的，避免因为有两个播放器引入复杂的上下文结构；

双路流的观影体验设计时较为超前的，在当前的硬件条件下，能够让配置不是很高的用户也能够畅享酷看模式是非常有挑战的。



《长安十二时辰》双流投放效果，母屏为正片，副屏为张小敬服饰介绍

4.1 主要的困难点：

1) 系统性的误差控制，需要全链路来保证

从视频生产开始，视频剪辑工具可能就具有 10ms 的以上误差，然后再经过运营平台录入锚点，如果运营工具做不到帧对齐级别的锚点自动计算，那么最终对齐的效果也会受人工计算锚点偏差的影响；事实上，从生产到投放，再到端侧解码渲染，这个系统误差一直在累积传递，对于这个误差的控制是个系统工程。

2) 播放器对做精准对齐提供的工具有限

播放器基础 Api 本身执行也在 10ms 这个量级，例如启动、暂停、Seek、变速等接口以及一些状态回调都是异步的，甚至系统的 sleep 精度也是有限的，这些方法本身的执行时机和耗时都是不确定的，调用这些 Api 实现 40ms 级别的同步就好像大象捉老鼠一般困难。

3) 设备多样性和运行随机性造成的适配困难

Android 设备碎片化严重，性能分布频谱宽广，在单次追帧同步过程中，运行时状态满随机性较大，无法事先给出全局通用的经验值作为参数进行补偿。

4.2 两个播放器同步的解决思路：

- 1) 首先要解决同步位置的锚定，这个位置目前是以主视频时间轴为基准，这里采纳主视频的时钟，有音频时钟，视频时钟或者外部时钟三种选择；
- 2) 要解决对齐的技术手段本身不精准的问题，对齐的技术手段较多，对齐的过程根本上是一个“调节 - 反馈 - 修正”的递归过程，虽然模型相对简单，但是需要达到想要的效果具体实现并不容易，涉及较多的实现技巧，例如提供更加精准的 seek 接口，尽量让这些 Api 产生的误差偏离方向一致，这样我们就便于在累积误差上做补偿；
- 3) 由于机型千差万别，运行时状态又充满随机性。这里就需要逐一梳理，消除随机性的影响。例如，为了适应网络状态的随机性，实现全局统一的缓存策略；为了平抑个体性能差异，我们引入了部分统计学的方法来做追帧补偿，统计当前设备最近几次追帧差值的方差和标准差作为下一次补偿追帧的参数；针对人眼对播放速度变化的敏感性，训练变速追帧的最佳变速曲线等。

通过架构设计、工程优化、算法升级和有针对性适配，打出全链路的组合拳，最终实现了多路流精准的同步播放，呈现了不错的效果。



《这就是街舞 2》中的同步效果

“浮沙之上难筑高台”，酷看模式在技术上创新是一个量变引起质变的过程，它得益于优酷乃至阿里集团在一些基础核心技术上的积累，酷看模式给用户提供更为丰富的沉浸式观影体验和丰富多样的互动方式，是非常有意义的探索，其中遇到的技术挑战让我们看到了一些不足，也为整个播放技术链路的发展指明了方向，希望“酷看”是一只“会下金蛋的老母鸡”。

《长安十二时辰》4k 和 HDR 的超高清体验


作者 | 阿里大文娱高级算法专家 张行

随着《长安十二时辰》的热播，相信大家也看到了《长安》上 HDR 和 4K 档位的效果，HDR 和 4K 正是优酷最近主打的超高清关键体验。


近年来，4K、8K 的电视越来越普及，LCD、OLED、投影机等各种观看设备也层出不穷，一个明显的趋势是：电视机屏幕越来越大，渲染表达能力也越来越强，观众的观赏要求也越来越高。原本 1080P 分辨率，SDR 的画面品质，已经很难打动用户了。针对这种情况，优酷投入了大量的精力，重点研发图像 Remastering 技术，把普通 1080P SDR 的介质，重制成 4K HDR 的版本，大大提升视频的渲染呈现效果。

一、HDR 高还原率的两个技术点

HDR (High Dynamic Range)，即高动态范围，其本质是还原更真实、更接近自然的图像。通过使用更高的量化精度把设备表达宽容度的能力提升到人眼水平，再现更大的色域和更高的亮度动态范围。



高动态范围



广色域

优酷 HDR 技术，通过云端和终端两级渲染，越过终端设备的解码器限制，打破高端机独享 HDR 服务的壁垒，实现内容，分发，体验的全掌控。通过优酷端到端的 HDR 技术，让目前市面上 70% 的手机，即使播放 SDR 介质，也能呈现出接近 HDR 的效果。



主要通过以下两个环节的技术实现：

一是智能云端渲染。将 SDR 内容在云上以 HDR 配置重新曝光，根据图像内容的智能调色，使得费时费力的 HDR 后期制作流程得以用机器批量完成；

二是个性化终端渲染。基于设备的屏幕亮度和色域空间，绕过后处理，实现云上渲染和端侧呈现的精准匹配，并且根据观影环境的不同进行适配，让手机用户在观影环境从黑暗到微光到室内光到户外光全程变化时，都可以有最佳的观影体验。

下面两张长安 HDR 与普通画质的对比效果，可以明显看到，HDR 画面的对比度更好，层次更丰富，颜色也更生动了。





二、2K 转 4K 的视频超分辨率算法 (SR)

除此之外，4K 是大屏幕观影的一个重要能力，但是由于拍摄和后期的诸多限制，现在多数的视频介质还是 1920×1080 分辨率。《长安》也不例外，1080 视频在大屏幕播放时，画面还是有一些毛糙的感觉。优酷通过高质量的 2K 转 4K 算法，把长安进行了 4K 重制，用户可以在 OTT 等大屏上，用超高清的 4K 画质观看《长安》。

超分辨率的核心是恢复图像的空间分辨能力，提升画面细节表达能力，本质是恢复信号的高频能量。这背后的思想是认为信号的高频和中低频之间具有相关性，可通过已有的中低频信息进行一定的高频反演。当然，这个反演比较复杂，是一个很高维的问题，一般是用深度卷积网络来做。事实证明，最近几年流行的各种 SR 网络的效果，远好于传统方法。

从 2K 到 4K 的超分辨率的三个实践方向：

第一是噪声的处理。噪声是一切图像增强算法的死敌，超分这里更是如此，因为相对有用信号而言，噪声更偏中高频，这正是超分要恢复增强的频带。如果处理不好，噪声很容易被放大，引起 badcase。优酷通过适量的加噪数据增强，训练网络，从而让网络具有抵挡噪声的处理能力。

第二是网络的使用。超分是一个很复杂的问题，尤其是对海量的互联网视频的场景，很难用一个网络解决各式各样的超分问题，所以我们把问题进行了细分，不同的

使用场景选择不同的网络，用不同的数据训练得到，专网专用。比如对于标清转高清的超分和 2K 转 4K 的超分就是独立的网络；即使同样的 2K 到 4K 超分，电影、电视剧、动画片也是独立的网络。网络独立的本质是把退化相近，数据分布相近的问题用一个网络处理，把退化差异大的问题分开处理，让每种超分问题都能有一个比较好的效果。

第三是训练数据的生成。网络能力是有限的，而且它的能力完全是我们用数据培养出来的，所以我们生成训练数据的时候，一定不能盲目，要根据实际问题场景，给网络生成恰当的训练数据，不能太简单，也不能太难。太简单的话，数据没有学习的价值，训练得到的网络能取得的超分效果肯定不明显；太复杂的话，比如要在一个均匀的 input 上去学细节丰富的 label，网络就会无所适从，容易出现过拟合等一些异常情况，不仅困难 case 解决不了，还会影响普通 case 的超分效果。

下面是我们对长安进行 4K 重制的效果对比：





4K 和 HDR 的重制更多集中在生产端。我们认为真正的超高清一定是要覆盖介质制作、转码生产、终端渲染全链路的各个环节，首先是拍摄制作端，要具备真 4K+HRD 的拍摄制作能力，提升高清介质源品质；二是生产端，用云端的 remastering 技术进行超高清流生产；三是播放端，联合终端厂商，适配终端设备，实现高清渲染呈现。

你追剧，机器学习帮你选档位，标清、高清、蓝光都不卡了 优酷智能档的三个技术挑战和解法

作者 | 阿里大文娱高级技术专家 肖文良

在你追《长安十二时辰》时，机器学习和大数据也没闲着，一直在后台帮你选“档位”，是标清、高清还是蓝光？会根据你的网络偏好、信号强度等智能地做选择。所以，你发现没，卡顿情况几乎没有了。这背后的技术原理是什么？

先分析下为什么会产生卡顿？

理论上，和人饿了就没力气一样，产生卡顿和缓冲的直接原因是视频数据不足。当播放器进入“饥饿”状态，就需要等待足够多的视频数据来恢复播放。但在真实场景下，网络信号质量变差、视频码率峰值过高、网络带宽竞争等等，都会导致视频缓冲。

在优酷，我们有多组技术小组都在针对各种播放场景进行技术优化。这其中就有“智能档”，它融合大数据分析、AI 机器学习等能力，通过动态化地播放与网络环境相匹配的最佳清晰度，来提升视频流畅度和观看体验。

智能档的技术原理

智能档的技术原理并不复杂，就是通过将不同码率、分辨率的视频文件，切分成 5-10s 的视频片段，并由算法实时动态决策适合播放的文件分辨率，通过动态的降低、升高观看视频的清晰度和码率，以适应复杂多变的外部网络环境，避免可能发生的视频缓冲。


优酷移动端的智能档



难点是，如何将理论付诸实践，让用户获得丝滑顺畅的观看体验。

目前，主流的自适应播放协议以苹果公司的 HLS（2009 年起草）、MPEG-DASH 协议（2010 年起草）以及近两年推出的 CMAF 协议为主。优酷智能档在起步阶段，结合业务需求与平台特性，选择以 HLS 协议为基础协议进行自定义的扩展和平台实现。

对智能档的直白理解



作为一个有着近 20 年的成熟业界应用协议，智能档的算法层面也有着非常丰富成熟的学术积累，使用“Adaptive Streaming”作为关键字，在 Google Scholar 搜索引擎检索，约有 100 万左右的论文结果。这些研究成果，也基本奠定了优酷智能档的算法框架和理论依据，并为前期的快速迭代上线提供了非常大的助力。

随着智能档的产品化以及迭代加速，即使站在巨人的肩膀，我们也很快就遇到新的挑战。

挑战一、高清和流畅的平衡点很难权衡

在学术界，高清与流畅的平衡往往是被转化为一个目标函数的优化过程，通过引入一个 QoE(Quality of Experience) 公式，将高清晰度的观看时长、卡顿次数、不同清晰度的切换频次等进行算法拟合，使用加权计算后的结果作为衡量算法表现的依据。

通过观察以下公式的计算因子，我们可以很容易地发现，计算结果其实与视频观看时长正相关：观看视频时间越长，得分越高，而卡顿、清晰度切换等负面行为的惩罚机制会被弱化。

一个典型的QoE计算公式

$$\underbrace{\delta_1 \sum_{k=1}^K q_p^k(l_p^k)}_{\text{Avg. Quality}} - \underbrace{\delta_2 \sum_{k=1}^{K-1} \left| q_p^{k+1}(l_p^{k+1}) - q_p^k(l_p^k) \right|}_{\text{Avg. Quality Switch}} - \underbrace{\delta_3 SE_p^k}_{\text{Stalls}} - \underbrace{\delta_4 T_p^{sd}}_{\text{Startup Delay}}$$

来自：SlideShare

而 QoE 类的计算公式带来的另一个问题是，它作为一个复合评分机制，有较多

的变量因素参与到计算中，因此线上 QoE 监控数据的波动变化，除了可以给出“整体的播放体验在变化”外，几乎没有其它任何信息可以提供给技术进行进一步的问题分析和优化。

技术解法：

针对上述两个问题，我们将 QoE 公式进行了时间维度的归一化调整，并建立了一系列中间技术观测指标，用来进行线上体验的监控度量、线下算法的优化。

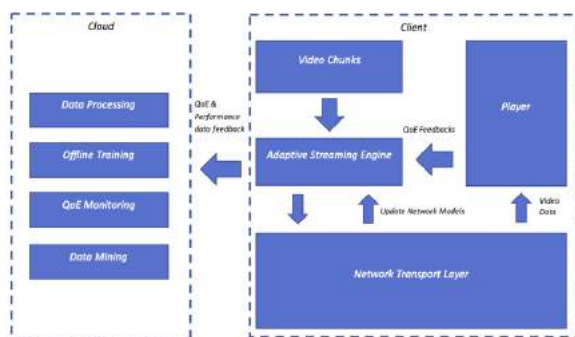
为了更快发现问题、更贴近用户使用场景，我们分别针对升降档的频次、清晰度的变化趋势、不同清晰度的缓冲频次、观看时长等，建立了完善的中间度量指标，来准确全面地观测智能档的真实表现。

$$QOE = \frac{\sum_{i=1}^N \mu_i T_i}{\sum_{i=1}^N T_i} - \tanh(0.05 * \sum_{i=1}^N B_i) - \frac{\sum_{i=1}^{N-1} \text{relu}(\mu_i - \mu_{i+1})}{N - 1}$$

挑战二、线下算法训练与线上实际效果的差距较大

目前，业界主流的算法以 MPC 极其衍生算法为主。MPC 是一个典型的工业领域的控制算法，尤其合适在复杂多变的环境中进行自我矫正，来执行特定的任务。如路径跟随控制、自适应导航算法等，在工业界取得了非常大的成功。在智能档算法中，典型的 MPC 算法通过将带宽、视频码率、缓冲时长等因素作为模型输入，以决策选择最佳播放策略。

优酷智能档系统示意图




阿里大文娱 | YOUKU | 优酷土豆集团 | 大麦 | 优酷网 | 阿里互动 | 优酷商城

在摩尔定律的加持下，计算机算力的指数级提升以及 GPU 并行计算模型的成熟等，将深度学习领域推向了新的巅峰，也带来了爆炸式的应用场景增长。

在优酷，我们也积极尝试基于深度学习、线性回归等不同方向的控制算法。其中，在深度学习算法 Pensieve(<http://web.mit.edu/pensieve/>) 的基础上的改良算法，已经开始进入了测试阶段。

在深度学习算法Pensieve的基础上的改良算法



阿里大文娱 | YOUKU | 优酷土豆集团 | 大麦 | 优酷网 | 阿里互动 | 优酷商城

无论是 MPC 算法还是机器学习算法，都需要 QoE 公式作为优化的目标函数，其算法内核都需要一组超参来对输入的特征变量进行动态决策。而模型的训练优化，离不开高质量的数据积累。

数据对模型表现的重要性，对于从事机器学习相关领域研究的读者来说是不言而喻的。对于不熟悉的读者，我们可以将数据与模型的关系类比为“课本与学生”的关系，当课本中的知识错误或者脱离了实际的应用场景，那么通过学习课本而获取知识的学生，也必然在实际的环境中处处碰壁。

例如，使用 Pensieve 算法依赖的公开网络数据集训练出来的模型，在我们实际的应用中，尽管在训练阶段取得了不错的结果，但是上线后的泛化能力较差，导致播放体验差强人意。因此，我们正在基于优酷海量用户行为数据，建立与完善一套高质量的网络模型数据集，来持续优化算法模型，提升用户播放体验。

技术解法：

针对模型算法的可解释性较差，严重依赖高质量数据训练的弊端，我们自主研发了基于规则、Buffer、MPC 等不同策略的复合模型算法，并结合在流媒体播放领域积累多年的核心技术积累，在实际应用中取得了非常好的成果，其中高清视频播放时长占比较业界算法有 5%-10% 左右提升，卡顿次数下降 10%-20% 左右。

挑战三、实际的用户体验需要更“智能”

任何算法策略，既需要数据喂养，以实现迭代优化，更要符合现实场景需求。智能档上线初期，我们常听到用户反馈说智能档“很傻”，或者觉得“莫名其妙”。通过对用户反馈场景的复现、日志分析排查等，我们更加意识到，智能档的策略绝不能仅停留在算法层面的”选择最优解“上。

例如，由于典型的智能档算法在优化目标函数时，总是倾向于避免缓冲、减少切换频次等来获取更高的 QoE 得分，而逐渐变得”功利“起来：**它更倾向于使用一个较低清晰度的开始播放，在网络质量不太理想的场景下，更不愿意作出”乐观的“尝试，避免因错误的判断而导致得分变低。**这就会让实际的播放体验变得较差，用户自然认为算法不够智能，因为“我的网速明明可以播 1080P，为什么要总是给我放

高清”，或者“清晰度总是一会儿变模糊，一会儿变清晰”。

这些“不智能”的表现，主要是因为传统算法往往是在实验环境下构建，并且进行了问题的抽象和简化，使得通过 QoE 度量的用户体验，略显单薄。

从真实用户体验出发，我们将智能档的体验标准进行了更细致地描述：

- 总是用符合我预期的清晰度播放，不论是“开始播放”还是“播放中快进”等；
- 对视频清晰度有强烈诉求的用户，要避免频繁的降低清晰度；
- 手机流量比较紧张的用户，要更多使用较低清晰度播放。

技术解法：

基于这些认知，通过建立用户偏好画像、网络度量模型、典型场景划分等手段，我们正在为不同诉求的用户提供个性化的智能策略。例如，得益于日益完善的网络度量模型以及智能档算法优化，偏好“高清”播放体验的用户已经能够在 92% 的观看时间内，享受到最佳画质。而流量比较紧缺的用户，又能在流畅观影的前提下，以最合适的清晰度享受最好的观看体验。

最后，作为一个程序员，我的目标就是“没有卡顿”。当然，这更是优酷智能档的技术方向，在“不卡顿”之上，为不同用户提供差异化的最佳播放体验。

爆红《长安》也是盗链者眼中的“肥肉”， 阿里专家解析防盗链系统

作者 | 阿里文娱高级技术专家 际星 技术专家 弥少

“一旦有适当的利润，资本家就胆大起来……有 50% 的利润，它就铤而走险；为了 100% 的利润，它就敢践踏一切人间法律；有 300% 的利润，它就敢犯任何罪行，甚至甘冒绞首的危险。”

这句名言同样适用于“盗链”的黑灰产业链，甚至由于法律的尚不完备，他们无需冒绞首的危险。

可以说《长安十二时辰》有多火，被盗链风险就有多大。截至 2019 年 7 月底，数亿次的盗链请求向《长安》袭来。面对如此邪恶压境之势，优酷技术团队早已布下天罗地网，弹指间即让“盗链”灰飞烟灭。

数亿次盗链偷袭 VS 零损失，这背后是怎样的技术架构与算法防御？

一、《长安》的超高流量被无数盗链者觊觎

在真金白银的利益诱惑下，大量以盗链为生的聚合网站和 App，类似网络视频领域的寄生虫，不采购版权、不架设 CDN，仅通过伪装成正常的客户端或浏览器访问，吸食正版视频网站的资源和宽带为自己的获利。正规的视频网站呢？用户被劫走、广告收入被过滤、每月浪费的宽带费用以千万计算，安装量越高，受害越严重。

《长安》的超高流量，也成为盗链团队觊觎的珍宝。造成的危害主要有以下：

- 1) 盗链造成巨大的版权损失，损害内容生产产业链，如人人都想通过“盗链”不劳而获，那谁还能真心生产内容；
- 2) 用户体验受损。盗链造成 CDN 带宽的严重消耗，影响正常用户观看体验，出现无法忍受的卡顿、等待时间太长等现场；
- 3) 对视频平台造成无法估量的损失，如用户流失、投资受损、口碑受影响等。

二、优酷全链路防盗链体系

1. 全链路 + 立体化防盗链体系

一个合规的播放链路，包含客户端、播放基础服务、CDN 等多个链路，任何一个漏洞都是盗链者可以切入。我们必须从全链路层面来审视防控的方案，建立行之有效的整体治理系统，这就是优酷的防盗链系统，这套系统由三层组成：

第一层，特征数据。就是对优酷整个播放链路进行“数据联通”，一个播放过程对应一个唯一的播放 ID，通过此 ID 将行为和路径完整的串联，并建立设备维度、用户维度、视频维度等行为数据表。



第二层：防控策略。防盗链系统实时动态的对数据进行汇总和分析，监控带宽、策略、盗链占比、用户行为变化，输出到防控系统。我们采用基本参数校验、黑白名单、渠道特征等多层防控系统，每一层应对不同层次的安全风险，防盗链系统始终在动态迭代，在数据的“喂养”下，渐强渐勇。

第三层，执行平台。有了防控体系、防控后台服务，在发现盗链的时需要快速的配置策略。防盗链管控系统能够随时控制、随时配置、实时监控盗链流量。

2. 多维度融合防控

盗链的唯一目标是盗取视频的播放地址，所以它会尽可能伪装成正常用户“获取”播放地址，但是总会在某些请求链路和方式上留下蛛丝马迹，而且这些盗链的特征会帮助我们发现盗链者。基于此我们建立了多维度防控体系，包括基于低阶维度特征的专家系统和基于高阶行为分析的 AI 模型方案。

1) 低阶维度特征的专家系统

盗链方会伪造各种参数模拟一个合法用户，包括但不限于 refer、UA、IP、userid、mac 地址、视频 ID 等，通过盗链特征分析，寻找异常点。

- a. **例如在 IP 维度**，离线盗链会经过服务器做代理，所以 IP 会有一定集中性，而实时盗链 IP 会不断变动，虽然没有集中性，但在行为上会有连续性。比如 1 小时前某个 IP 有盗链行为，那么下个时间段此 IP 出现盗链的概率也增加。
- b. **例如在视频 ID 维度**，某些盗链网站会把自有的内容上传到优酷 CDN 并以盗链方式进行播放，这些内容在正规优酷上不会透出，通过视频维度聚合既可以找到异常影片。基于这些特征的专家系统，可以对部分初级盗链者进行防控。

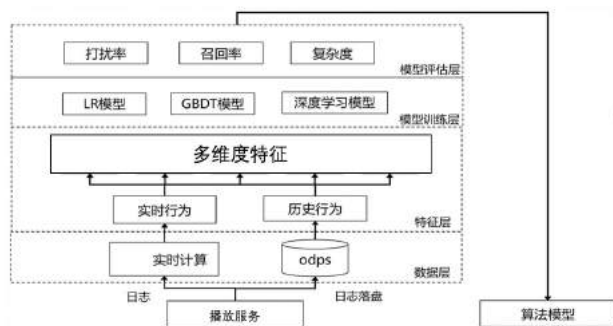
2) 高阶行为分析的 AI 模型

敌人是狡猾的，一些高级别盗链方伪装成合法用户的程度越来越高，仅采用低阶特征已经无法提高防控比率。优酷引入 AI 算法，对大量播放行为数据进行挖掘，建立“盗链者”行为模型。

$$M(f(userid), f(videoid), f(ip), f(token)...) \in (0,1)$$

构建盗链模型，通过分析用户的实时和历史行为，将不符合正常用户行为的请求进行拦截，提高盗链防控率。

基于多维度特征的AI模型



经过线上实际测试，我们的 GBDT+LR 模型上线后比原专家系统防控效果提升了 1.5 倍，达到了预期。

大道至简，我们通过构建防盗链数据体系、全链路防控系统、实施对抗平台，采用多维度防控手段，防盗链系统服务经受住大流量、长保障和多类攻击的考验，在大剧大综、2018 世界杯直播、2018 天猫晚会直播等优酷版权内容上取得了很好的效果。

由于盗链的诱惑巨大，防盗链始终是“魔高一尺，道高一丈”的交错过程，我们会在现有基础上进一步加大防控网，同时和法务配合积极向法律界、学术界等进行交流，促进各行业版权保护的协同效应。

“上元已至”，让我们防盗链系统和张都尉一起来抗击“盗链狼卫”，保护“视频行业”的繁荣和安宁。

详解优酷媒资中台架构： 日均百亿调用下的高可用平台

作者 | 阿里大文娱无线开发专家 孤漠

媒资中台承载着优酷全站媒资数据的存储、查询及搜索工作，是介于上层分发侧业务和生产方之间的中间层，为优酷业务体系提供核心数据的存储、输出和技术支持，是优酷最核心最基础的后台服务之一，每天承载了百亿级的 API 调用，为下游业务提供了高可用低延迟可扩展的架构支撑。

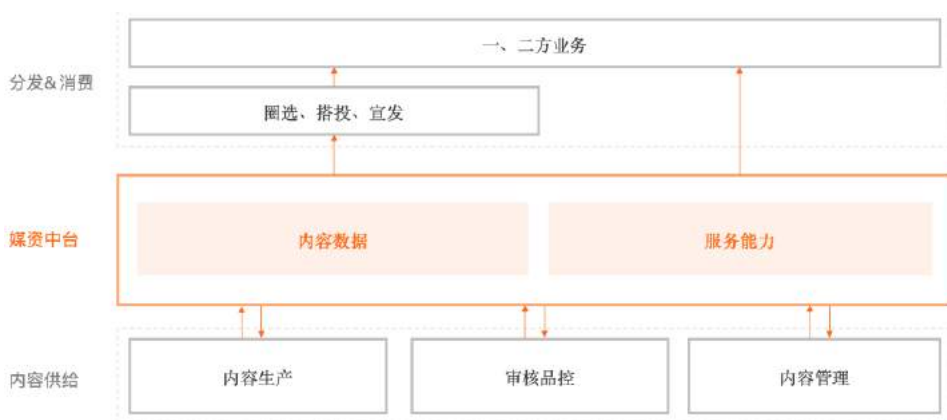


图 1 媒资中台在优酷体系中的定位

在媒资中台之前的媒资系统，存在着字段变更不易、数据使用不便、搜索范围及方式不够灵活、数据不够全面等诸多问题。为了更好的服务好各业务方，媒资中台分别在底层存储、搜索、数据聚合等方面做了许多优化。

一、底层存储及领域模型设计

优酷在“远古时代”的媒资系统使用 MySQL 作为数据存储，包括节目表、节目扩展表、节目类目表、节目别名表、节目收费表、节目评分表等上百张 MySQL 表，而且经常有产品和运营需求需要增加字段，需要开发资源排期，并且数据库表和字段

数量逐渐膨胀到难以维护。

根据对老媒资系统的业务抽象，我们对于媒资数据抽象出实体和属性两层概念。根据业务需求，在新媒资系统中，抽象出节目、视频、人物、中插点等若干实体，实体拥有若干属性，是对实体的描述。根据属性类型的不同，我们又将属性区分为基本属性、枚举属性、关联属性，单值和多值属性等。如图 2 所示。

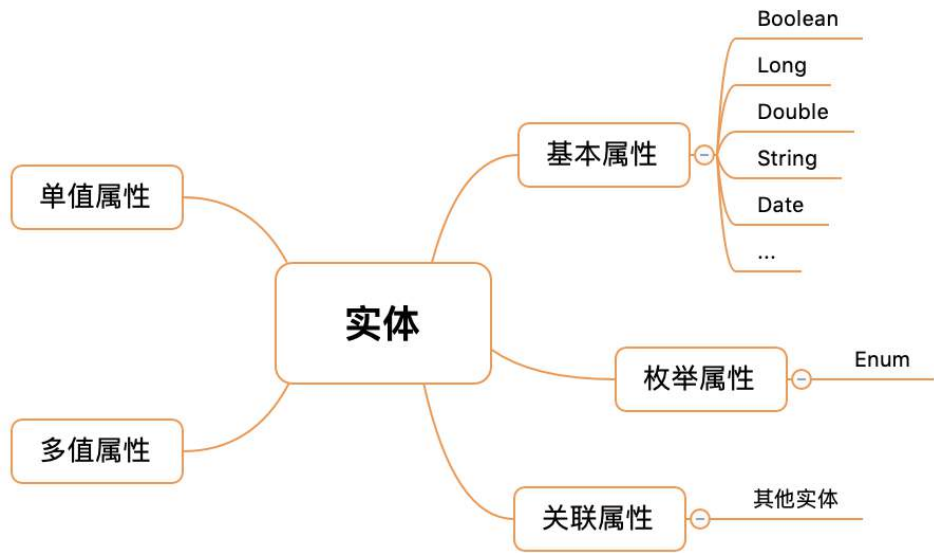


图 2 媒资实体和属性

1. 基本属性，是一种最基础的实体属性，用于描述实体的数值型、字符串型、日期型等基本类型的属性。
2. 枚举属性，主要为了更好的表示某些拥有特定枚举值的实体属性，是媒资系统中最重要的属性类别之一。
3. 关联属性，用于表示实体和实体之间的关联关系。例如《长安十二时辰》节目和导演的关联关系，是通过关联属性进行表示的。
4. 多值属性，每个属性都被区分为单值属性或多值属性。多值属性用于表示取值可能为多值的属性，例如《长安十二时辰》存在多个演员，因此节目的演员是一个多值属性。

通过实体和属性的抽象，优酷媒资系统可以任意扩展实体和实体属性，并通过关联属性将实体和实体进行关联，以此实现大优酷的媒资编目，并用于前台分发。

优酷媒资中台使用 Ali-Hbase 作为数据存储，能够动态增加数据表和列，实现媒资实体和属性的动态扩展。产品和运营能够根据业务需求，随时新增实体和属性，而不再需要等待媒资开发资源排期。

在老媒资系统中，业务方获取数据时，需要熟知要获取的字段名称及类型，然后通过接口传入字符串类型的字段名称，在返回值中根据各字段类型分别强制转换为对应的类型。这样不仅开发难度大，联调困难，出现问题的概率也大大增加。媒资中台为了解决这个问题，引入了数据 SDK，通过将字段源信息提前编译为 java 文件，用户在使用时无需关心字段名称是否合法，也天然可获取字段类型，再通过简单易用的查询语法和 api，业务方可快速进行媒资数据开发。



```

{
  "code": "SUCCESS",
  "data": {
    "id": 123,
    "name": "xxx",
    "date": "2019-01-01 00:00:00",
    "state": "normal",
    "gender": "M",
    "desc": "yyy",
    "type": [
      "type0",
      "type1",
      "type2",
      "type3"
    ]
  }
}

```

```

@Data
public class EntityDTO {

    private Long id;

    private String name;

    private Date date;

    private State state;

    private Gender gender;

    private String desc;

    private List<String> type;
}

```

图3 老媒资系统数据返回示例及媒资中台实体领域模型对比

二、搜索设计

媒资数据存在大量检索需求，例如查询某节目下的可播正片或查询某演员出演的所有节目，这些需求在面向终端用户的前台场景和面向媒资运营及离线任务的后台场

景中都会出现。前台场景和后台场景都需要检索来自不同实体中的字段，并希望在数据发生变化后能查询到最新的数据，检索的字段还会随着业务的发展不断新增。前台场景和后台场景又有着不同的需求，前台场景对 rt 敏感，但只需在前台可见数据范围内检索部分字段；而后台场景可以容忍较高的 rt，但需要支持全量数据绝大部分字段的检索。考虑到媒资数据字段的动态性以及查询需求，我们采用 elasticsearch 搭建媒资数据查询服务。

我们首先从前台场景和后台场景的共性出发进行设计。从索引配置的角度，索引配置与实体配置相互独立，一个索引中的字段可来源于多个实体，并且可配置只索引满足某条件的数据；同一索引中的不同字段刷新频率可配置，频率根据延迟需求以及更新代价权衡得出。从查询语言的角度，所有类型的字段均支持精确匹配和非空查询，对于整数、浮点数、日期、可选日期类型还支持范围查询，对于枚举、字符串类型还支持精确包含和模糊匹配，对于数组类型支持元素个数精确查询和范围查询。从查询执行的角度，我们将以 id 作为查询条件的请求直接路由至点查询服务，并对查询条件进行优化，将不需要进行分数计算的查询子句提取出来，作为 filter 传递给 elasticsearch，最大限度地利用其缓存。对于查询常见的深度翻页问题，我们通过 elasticsearch 的 search_after 解决。

接下来我们从前台场景和后台场景的差异出发。从集群的角度，我们搭建了前台检索集群和后台检索集群。通过将前台流量和后台流量隔离到不同集群，我们防止了后台流量对前台流量造成影响。从数据的角度，我们从业务场景出发，为前台场景和后台场景定制不同索引条件及索引字段。从性能的角度，我们根据前台场景和后台场景所容忍的 rt、常见查询条件，对前台集群和后台集群进行压测，分别得到了索引和查询参数的阈值。

由此，我们满足了媒资数据的检索需求。

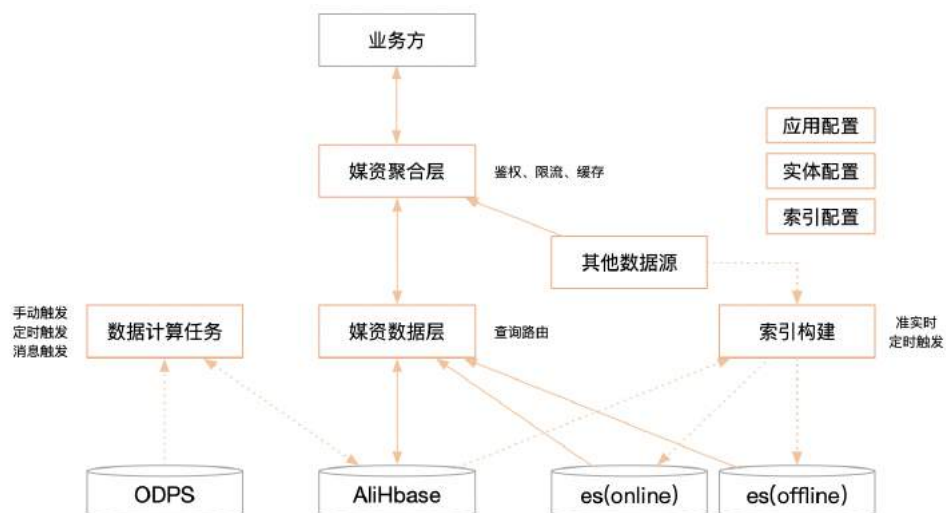


图4 媒资中台搜索架构设计

三、数据聚合及计算

随着视频业务的多元化发展，媒资数据爆发式增长的同时，不同的生产方提供数据的方式也各不相同，有的提供离线 ODPS 表，有的需要从在线 HTTP 或 RPC 中获取，有的通过 MQ 发送，还有的要直接读 DB。业务方如果直接从各原始数据源读取，将会是一个巨大的挑战。

为了更好的服务上层业务方，媒资中台通过数据聚合层和数据导入层，屏蔽了底层数据源差异，数据提供方只需简单注册数据源并绑定字段，即可通过媒资中台统一接口对外提供服务。数据使用方也只需对接媒资中台，按统一方式获取数据即可。

业务方使用数据还要另外一个痛点：重复计算。业务方取出原始数据后，要对数据进行清洗和计算，这就会导致相同的业务逻辑无法复用，业务方开发难度大且周期长，同时会造成大量的计算资源浪费。且对业务逻辑的理解因人而异，会造成相同的业务逻辑在不同的业务方统计口径不一致，又会浪费大量的资源在数据校对上。针对此类痛点，媒资中台提供了数据计算服务，可以将通用的业务逻辑沉淀在媒资中台，用户可注册字段级的计算任务，简单计算可通过内置方法，复杂计算可以上传自定义

代码包，同时可调整同一字段任务的优先级。

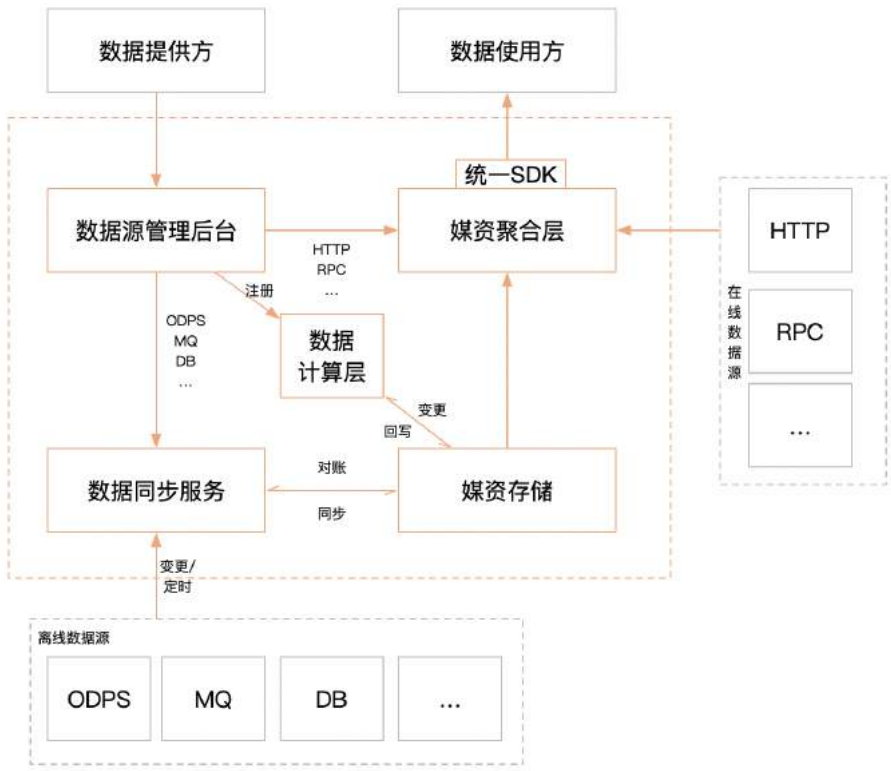


图5 媒资中台数据聚合及计算架构设计

四、总结

媒资中台承载着优酷全站的媒资数据，为优酷所有业务方提供了简单快捷的数据获取服务，保障着优酷全站用户的播放体验。

媒资中台仍在高速发展快速迭代中，我们会继续在优酷媒资管理领域积极行动，继续深挖业务方在使用媒资数据时的痛点，提供更加准确、全面的媒资基础服务。



优酷技术品牌出品



「阿里文娱技术」公众号



「阿里云开发者社区」



「阿里技术」微信公众号

扫一扫二维码图案，关注我吧